

La nueva idea de tesis consiste en desarrollar un asistente robótico doméstico que permita a una persona realizar tareas a distancia dentro de su casa mediante instrucciones naturales. Estaría dirigido a personas que **pueden utilizar normalmente sus brazos y manos, pero no pueden desplazarse** para buscar, transportar o recoger objetos.

El robot utilizaría DimensionalOS para organizar sus capacidades y aprovechar sus módulos de navegación, mapas, memoria y percepción; un VLM interpretaría las instrucciones junto con la información visual; y varias políticas ACT, integradas como skills, ejecutarían las manipulaciones aprendidas. Una interfaz permitiría solicitar tareas, observar el progreso y responder a consultas.

Lo siguiente es una **propuesta de trabajo provisional**: define una dirección coherente, pero deja abiertos el modelo VLM, las tareas definitivas y algunos mecanismos de integración.

1. La problemática se centraría en el acceso autónomo a objetos y recursos del hogar.

Una persona que no puede desplazarse puede necesitar ayuda para acciones cotidianas como traer una botella, recuperar un control remoto caído o acercar objetos desde otra habitación. Aunque pueda utilizarlos por sí misma, depende de que alguien los ponga a su alcance.

La tesis buscaría reducir esa dependencia para un conjunto concreto de tareas. El resultado deseado sería que la persona pudiera expresar qué necesita y recibirlo en una ubicación accesible, sin dirigir cada movimiento del robot.

Esta delimitación ayuda a elegir tareas realizables: entregar una botella sobre una mesa puede resolver completamente una necesidad del usuario objetivo. La propuesta se concentraría en **buscar, recoger, transportar, colocar y organizar objetos**, con alguna manipulación bimanual cuando aporte utilidad.

2. El proyecto podría formularse inicialmente de esta manera.

Un título tentativo sería:

Arquitectura modular de asistencia doméstica mediante navegación semántica y habilidades de manipulación aprendidas en un robot móvil bimanual.

El objetivo general podría ser:

Desarrollar y evaluar una arquitectura robótica modular que permita a personas con limitaciones para desplazarse solicitar tareas domésticas mediante lenguaje natural, integrando memoria y navegación semántica, planificación con contexto visual y políticas de manipulación aprendidas, con una interfaz accesible y un repertorio de habilidades ampliable.

El costo, la autonomía y la facilidad de ampliación serían dimensiones de evaluación. Todavía convendría tratarlas como **mejoras que queremos demostrar**, antes de afirmar que el sistema será más económico o autónomo que las alternativas.

3. La arquitectura distribuiría las responsabilidades entre componentes especializados.

Componente	Responsabilidad prevista
Interfaz y comunicación por voz	Recibir solicitudes, mostrar información y comunicar resultados
VLM planner	Interpretar la petición, consultar el contexto y proponer etapas utilizando habilidades disponibles
Memoria y percepción	Recuperar observaciones anteriores e identificar objetos y estados actuales
Navegación semántica	Convertir destinos como “estante de la sala” en desplazamientos
Gestor de ejecución	Coordinar las etapas, comprobar requisitos y gestionar finalización, pausa o fallo
Skills de manipulación con ACT	Ejecutar movimientos aprendidos para objetos y situaciones determinados
Control del robot	Aplicar comandos a base, lift, brazos y pinzas, respetando sus límites

La relación principal sería:



DimensionalOS actuaría como entorno de integración. El gestor de ejecución puede implementarse aprovechando sus mecanismos disponibles; aquí aparece separado porque cumple una responsabilidad diferente de la interpretación del lenguaje.

4. DimensionalOS sería la base reutilizable, y su adaptación al AlohaMini2 formaría parte del trabajo.

La documentación actual presenta capacidades de mapas, relocalización, memoria espacial y herramientas como `navigate_with_text`, `tag_location` y `observe`. También permite exponer habilidades para que un agente las invoque. [Agentes y skills de DimOS](#).

Podemos apoyarnos en esas capacidades, pero **tener esos módulos disponibles no significa que toda la combinación AlohaMini2 + L2 + D435i funcione directamente**. Habrá que comprobar las interfaces de sensores, odometría, comandos de la base y control de los manipuladores.

El hardware cumpliría estas funciones previstas:

- **AlohaMini2:** desplazamiento, ajuste de altura y manipulación con uno o dos brazos.
- **LiDAR Unitree L2:** información geométrica para los módulos de localización, mapas y obstáculos compatibles.
- **RealSense D435i:** imágenes y profundidad para observar objetos y superficies.
- **Cámaras adicionales, si resultan necesarias:** vistas cercanas cuando los brazos oculten el objeto a la cámara superior.
- **Micrófono, altavoz y red doméstica:** comunicación e interfaz.
- **Equipo de cómputo:** ejecución de los módulos y modelos seleccionados.

La distribución del cómputo entre robot y equipo externo quedaría abierta hasta medir latencia, memoria y consumo. El control físico debería poder responder a una parada aunque el VLM esté tardando en contestar.

5. El mapa y la memoria aportarían información diferente y complementaria.

Propondría distinguir tres elementos:

Elemento	Qué permitiría saber	Ejemplo
Mapa geométrico	Dónde puede circular y cómo llegar	Pasillo que conecta sala y dormitorio
Referencias semánticas	Cómo se llaman lugares y superficies	Cocina, estante, mesa auxiliar
Memoria de observaciones	Qué se vio, dónde y cuándo	Control remoto observado sobre una mesa

La documentación de navegación de DimOS describe mapeo durante el recorrido y un flujo de mapa previo con relocalización, actualmente explicado para Go2. Ese flujo es una

referencia para preparar la casa, aunque su adaptación a nuestra plataforma debe verificarse. [Mapeo y relocalización en DimOS](#).

La preparación inicial podría consistir en recorrer las zonas accesibles, guardar el mapa, asociar nombres a habitaciones y muebles y registrar los puntos de entrega.

“Mapa completo de la casa” debería entenderse como cobertura de las zonas que el robot puede recorrer y observar. No implica conocer el contenido de un cajón cerrado ni la posición actual de todos los objetos.

La memoria espacial documentada almacena observaciones vinculadas a posiciones y tiempos, y permite búsquedas semánticas mediante representaciones de imágenes y texto. Esto puede servir para recuperar lugares donde anteriormente se observó algo relacionado con la solicitud. [Memoria espacial de DimOS](#).

Nuestra propuesta sería aprovechar esa base para orientar la búsqueda, manteniendo una distinción visible entre:

- Lugar habitual de un objeto.
- Última ubicación observada.
- Ubicación confirmada durante la tarea actual.

Si alguien mueve el control remoto después del recorrido, el robot tendría que volver a localizarlo. La memoria proporciona una pista; la observación actual confirma la situación.

6. El reconocimiento semántico combinaría las capacidades disponibles en DimOS con percepción visual cuando haga falta.

Para recoger una botella necesitamos resolver preguntas progresivamente más concretas:

1. ¿Dónde conviene buscarla?
2. ¿Qué elemento de la imagen corresponde a la botella solicitada?
3. ¿Dónde se encuentra respecto del robot?
4. ¿Está en una situación compatible con alguna habilidad entrenada?

DimOS documenta también un sistema experimental llamado **WorldBelief**, asociado a xArm6, que procesa observaciones RGB-D para mantener identidades de objetos entre escaneos y reinicios. Podría investigarse su reutilización, pero aún sería una opción experimental por validar en nuestro caso. [Percepción y WorldBelief de DimOS](#).

Por eso, la formulación prudente de la tesis sería:

Se aprovecharán los módulos de memoria y percepción de DimensionalOS y se complementarán, cuando sea necesario, con herramientas visuales para identificar y localizar los objetos requeridos.

El VLM podría interpretar la escena; un detector o segmentador podría delimitar objetos; y la profundidad, junto con la calibración, permitiría relacionarlos con el espacio físico. La combinación definitiva dependerá de lo que ya resuelva satisfactoriamente DimOS.

7. El VLM planner interpretaría la intención y la conectaría con la escena y las habilidades disponibles.

Sus entradas previstas serían:

- La instrucción transcrita.
- Las habilidades instaladas y sus requisitos.
- Información recuperada de la memoria.
- Imágenes actuales o resultados de herramientas visuales.
- El estado del robot y los resultados de las etapas anteriores.
- El destino de entrega y las preferencias del usuario.

Ante:

“Tráeme la botella del estante y déjala junto a mí”.

Podría proponer: localizar el estante, navegar, identificar la botella, preparar la manipulación, recogerla, transportarla y depositarla en el punto de entrega correspondiente.

El plan podría actualizarse cuando aparezca información nueva. Por ejemplo, si el objeto ya está en la bandeja del robot, no tendría sentido ir a buscarlo nuevamente.

Su función visual tendría tres prioridades:

Función	Ejemplo
Identificar el objetivo dentro de la escena	Reconocer el control remoto solicitado
Interpretar estados necesarios para actuar	Observar que una caja está cerrada
Ayudar a comprobar resultados	Detectar que falta un objeto en la bandeja

La verificación combinaría las imágenes con la información física disponible. Una imagen puede mostrar que la botella se desplazó, pero el estado de la pinza y otras señales ayudan a determinar si continúa sostenida.

El planner solo debería seleccionar habilidades que el sistema realmente tenga disponibles. Reconocer una botella o comprender “abre el refrigerador” no implica que el robot sepa manipularla o abrirlo.

El modelo VLM concreto y un posible fine-tuning seguirían abiertos. Una primera versión puede evaluar un modelo preentrenado con herramientas bien definidas antes de decidir si requiere entrenamiento adicional.

8. Las políticas ACT constituirían el repertorio de habilidades físicas aprendidas.

Podríamos comenzar con políticas como:

- Recoger una botella desde una superficie.
- Recoger un control remoto.
- Depositar un objeto sobre una mesa.
- Levantar y depositar una bandeja con ambos brazos.
- Abrir una caja de tapa sencilla mientras otro brazo la estabiliza.

No es necesario imponer una política por objeto individual. Una misma política podría cubrir varios objetos o variaciones si se entrena y evalúa para ello.

ACT estándar procesa imágenes y estado articular para producir secuencias de acciones. No recibe automáticamente el significado de la instrucción del usuario. [ACT en LeRobot](#).

Por tanto, **debemos diseñar cómo la selección del objetivo por el planner se convierte en una ejecución ACT adecuada**. Para empezar, podríamos utilizar políticas especializadas y preparar una posición inicial consistente del robot. Si después necesitamos seleccionar entre varios objetivos dentro de la misma escena, habría que evaluar condicionamiento por objetivo u otra adaptación entrenada.

La navegación también tendría que finalizar en una posición útil para manipular. Llegar cerca del estante puede ser suficiente para observarlo, pero todavía puede hacer falta ajustar distancia, orientación y altura.

Para simplificar la primera versión, podríamos alternar navegación y manipulación con la base detenida durante el agarre. La coordinación simultánea de base, lift y brazos quedaría como una posible ampliación.

9. Cada política se integraría como una skill con requisitos y resultados claros.

La skill sería una envoltura funcional alrededor de la política:

Información de la skill	Para qué sirve
Nombre y descripción	Permitir que el planner sepa cuándo utilizarla
Objetos y situaciones compatibles	Delimitar lo que realmente se ha entrenado
Checkpoint y configuración	Cargar la política correcta
Cámaras y estado requeridos	Preparar observaciones compatibles
Condiciones iniciales	Evitar iniciar desde una postura inadecuada
Condiciones de finalización	Determinar éxito, fallo o resultado no verificable
Estado final esperado	Permitir continuar con otra habilidad
Mecanismos de pausa y cancelación	Interrumpir la ejecución de manera controlada

DimOS ya dispone del registro mediante `@skill` y descubrimiento automático. Nuestra aportación se centraría en **adaptar, validar y componer políticas ACT para misiones asistenciales**, aprovechando ese mecanismo existente.

Por ejemplo, después de instalar una nueva habilidad para abrir una caja, el robot podría combinarla con habilidades anteriores para sacar un objeto y llevarlo al usuario. No sería necesario volver a entrenar toda la misión, siempre que las condiciones de salida y entrada sean compatibles.

La ampliación sencilla sería un objetivo comprobable. Mediríamos por separado el esfuerzo de demostraciones, entrenamiento e integración, evitando confundir “instalar un checkpoint” con “enseñar una habilidad nueva”.

10. La comunicación y la interfaz permitirían al usuario dirigir la asistencia y conocer su progreso.

La interfaz podría ser una aplicación web adaptable a celular y laptop.

Función	Comportamiento propuesto
Solicitud por voz o texto	Enviar una tarea con lenguaje natural
Indicador de escucha	Mostrar claramente cuándo se está capturando audio
Transcripción	Consultar y corregir lo que se entendió
Estado de la misión	“Buscando”, “recogiendo”, “en camino” o “necesito una aclaración”

Función	Comportamiento propuesto
Cámaras	Ver la escena y cambiar entre vistas disponibles
Mapa	Mostrar posición del robot, destino y habitaciones
Consultas	Responder por voz, texto o selección visual
Punto de entrega	Elegir dormitorio, sofá o una mesa previamente registrada
Pausa y cancelación	Interrumpir o modificar una solicitud
Historial y favoritos	Repetir tareas frecuentes y revisar resultados
Estado básico del robot	Consultar batería y conexión

DimOS ofrece un cockpit y un Web SDK que podemos evaluar como base. La documentación distingue el modo local de desarrollo del despliegue remoto, por lo que el acceso desde el celular requerirá resolver expresamente la conexión y el acceso entre dispositivos. [Web SDK de DimOS](#).

Hay dos detalles prácticos que conviene resolver desde el inicio.

Primero, si la persona está en el dormitorio y el robot en la sala, el micrófono del robot podría no escucharla. Una primera solución sería usar el micrófono del celular o laptop. La activación “Hey robot” podría incorporarse después o utilizarse cuando haya cobertura de audio suficiente.

Segundo, recibir una instrucción no indica automáticamente dónde está la persona. Propondría seleccionar un lugar desde la interfaz o decir “estoy en mi dormitorio”, asociándolo a un punto de entrega registrado. La localización automática de la persona podría añadirse posteriormente.

Cuando exista ambigüedad, el robot preguntaría directamente y conservaría el contexto de la misión. Esta consulta sería una función de interacción del sistema.

11. Una misión completa mostraría cómo se conectan todos los módulos.

Supongamos que la persona solicita desde su celular:

“Tráeme la botella de agua del estante de la sala y déjala en la mesa de mi dormitorio”.

El flujo previsto sería:

1. La interfaz captura la voz, muestra la transcripción e indica que la solicitud fue recibida.
2. El planner identifica el objeto, el lugar de búsqueda y el destino.
3. Se consulta la memoria y se recupera la referencia del estante.
4. La navegación lleva al robot a una posición desde la que pueda observarlo.
5. La percepción actual identifica la botella; si hay varias compatibles, el robot consulta.

6. El gestor comprueba que la botella está dentro del alcance y del dominio de una skill disponible.
7. Se ajustan la base y la altura necesarias y se ejecuta la política ACT.
8. Se verifica el resultado del agarre y se prepara el transporte.
9. El robot navega hasta el punto de entrega.
10. Ejecuta la colocación, comprueba el resultado y notifica al usuario.

Si la botella no aparece, el sistema podría revisar otras observaciones o consultar al usuario. Si la manipulación falla, podría realizar un reintento limitado cuando exista una estrategia válida, o informar del problema.

El éxito se definiría como **entregar el objeto correcto en una posición accesible**, no únicamente completar una secuencia de movimientos.

12. Las tareas definitivas deberían equilibrar utilidad y viabilidad.

Un repertorio inicial razonable sería:

Misión candidata	Utilidad	Capacidad que permite evaluar
Traer una botella desde otra habitación	Acceso a una bebida	Misión completa de navegación y manipulación
Traer teléfono, control o estuche de lentes	Acceso a objetos personales	Selección entre categorías y políticas
Recuperar un objeto caído	Restablecer el acceso a un objeto	Manipulación desde una altura distinta
Llevar varios objetos en una bandeja	Resolver una solicitud compuesta	Composición de skills y manipulación bimanual
Retirar objetos usados de la mesa auxiliar	Mantener espacio accesible	Recogida, clasificación acotada y transporte
Abrir una caja y traer su contenido	Acceder a objetos almacenados	Ampliación del repertorio y coordinación de brazos

La recuperación desde el suelo dependerá del alcance y de la capacidad de las pinzas para sujetar el objeto. La bandeja dependerá de la carga y del espacio disponible para circular.

Para una primera tesis, **elegiría pocas misiones completas y reservaría una habilidad nueva para demostrar la ampliación de la arquitectura**. La selección final debería incorporar comentarios de posibles usuarios sobre qué solicitudes les resolverían necesidades frecuentes.

13. El aporte se defendería mediante resultados medibles del sistema completo.

La propuesta podría aportar en tres direcciones relacionadas:

- **Autonomía funcional:** completar tareas domésticas desde la solicitud hasta la entrega, reduciendo asistencia durante la ejecución.
- **Extensibilidad:** incorporar habilidades y combinarlas con las existentes con un esfuerzo de integración reducido.
- **Acceso y supervisión:** permitir que el usuario solicite, comprenda y modifique la asistencia desde una interfaz sencilla.

La evaluación podría organizarse así:

Dimensión	Qué mediríamos
Éxito de la misión	Proporción de solicitudes completadas correctamente
Intervención humana	Aclaraciones, rescates por teleoperación y ayuda física, registrados por separado
Tiempo	Duración total y tiempo de participación activa del usuario
Entrega accesible	Objeto colocado en la zona acordada
Ampliación	Tiempo y cambios necesarios para integrar una nueva skill
Robustez	Rendimiento ante posiciones, fondos y disposiciones diferentes
Utilidad del contexto visual	Diferencia al incorporar observación y verificación al planner
Costo	Hardware, sensores, cómputo, servicios y preparación necesaria
Usabilidad	Facilidad para solicitar tareas, entender el estado y corregir instrucciones

La comparación principal puede realizarse sobre el mismo robot con configuraciones controladas. Compararlo con otros sistemas publicados será útil para contextualizarlo, pero no permitiría afirmar superioridad directa si las tareas y condiciones son diferentes.

14. Algunas ampliaciones quedarían abiertas según lo que revele el prototipo.

Entre las opciones con utilidad práctica consideraría:

- **Preferencias de entrega:** recordar que el usuario prefiere los objetos en una zona determinada de la mesa.
- **Actualización de ubicaciones:** registrar dónde deja el robot los objetos que transporta.
- **Solicitudes compuestas:** combinar agua, teléfono y merienda en una misión.

- **Correcciones durante la ejecución:** cambiar el destino o retirar un objeto de la solicitud.
- **Nuevas habilidades bimanuales:** estabilizar recipientes, abrir tapas sencillas o manipular cestas.
- **Mejora de políticas a partir de fallos registrados:** como etapa posterior si la fiabilidad de ACT resulta ser el principal límite.
- **Adaptación del VLM:** si la evaluación muestra errores recurrentes al seleccionar o componer habilidades.

Las decisiones pendientes más importantes serían el repertorio inicial, el método de entrega y transporte, el modelo VLM, las vistas de cámara necesarias y la adaptación de los módulos de DimOS al AlohaMini2. Resolverlas con un primer ciclo completo —solicitar, buscar, recoger, transportar y entregar un objeto— nos daría la evidencia necesaria para concretar el alcance definitivo de la tesis.